



华中科技大学学报(自然科学版)

Journal of Huazhong University of Science and Technology(Natural Science Edition)

ISSN 1671-4512,CN 42-1658/N

《华中科技大学学报(自然科学版)》网络首发论文

题目： 人机协同巡检下绝缘子分类及故障检测方法
作者： 王少飞，吴琼水，田猛，王先培
DOI： 10.13245/j.hust.240215
收稿日期： 2022-07-06
网络首发日期： 2023-10-07
引用格式： 王少飞，吴琼水，田猛，王先培. 人机协同巡检下绝缘子分类及故障检测方法[J/OL]. 华中科技大学学报(自然科学版).
<https://doi.org/10.13245/j.hust.240215>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

DOI: 10.13245/j.hust.240215

人机协同巡检下绝缘子分类及故障检测方法

王少飞 吴琼水 田 猛 王先培

(武汉大学电子信息学院, 湖北 武汉 430072)

摘要 针对目前电网人机协同巡检过程中数据收集量、来源面和复杂度增加, 导致绝缘子目标小, 遮挡严重, 背景复杂, 故障难以识别等问题, 提出一种基于 Yolov5-TBT 模型的绝缘子分类及故障检测算法. 首先构建了多目标 (3 种类别+2 种故障) 的人机协同巡检数据集, 为模型训练提供充足的绝缘子图像, 提高模型的鲁棒性和泛化能力. 然后, 以 Yolov5 模型为基础, 增加 Transformer 编码器, 减少复杂背景的干扰; 使用加权双向特征金字塔网络(BiFPN) 学习不同层级输入特征的重要性, 进行更有效的特征聚合; 增加小目标预测分支, 提高对小目标的检测效果. 实验结果表明: 改进模型效果优于 Yolov5 模型, 对伞裙破损故障的检测精度提高了 19.4%, 整体性能提高 3.6%.

关键词 电网巡检; 绝缘子分类; 故障检测; Yolov5 模型; Transformer 编码器

中图分类号 TM769

文献标志码 A

Insulator classification and fault detection method under human-machine collaborative inspection

WANG Shaofei WU Qiongshui TIAN Meng WANG Xianpei

(Electronic Information School, Wuhan University, Wuhan 430072, China)

Abstract A Yolov5-TBT model based insulator classification and fault detection algorithm was proposed to address the issues of small insulator targets, severe occlusion, complex background, and difficulty in identifying faults caused by the increase in data collection, source area, and complexity in the current human-machine collaborative inspection process in the power grid. Firstly, a multi-objective (3 categories+2 faults) human-machine collaborative inspection dataset was constructed to provide sufficient insulator images for model training and improve the robustness and generalization ability of the model. Then, based on the Yolov5 model, the Transformer encoder block was added to reduce the interference of complex background. The weighted Bi-directional Feature Pyramid Network (BiFPN) was used to learn the importance of input features at different levels for more effective feature aggregation. A tiny object prediction branch was added to improve the detection effect of the tiny target. The experimental results showed that the improved model is better than Yolov5, the recognition accuracy of the shed damage is 19.4% higher, and the overall performance is improved by 3.6%.

Key words power grid inspection; insulator classification; fault identification; Yolov5 model; transformer encoder

绝缘子在架空输电线路中对导线支撑和防止电流回地等方面起到至关重要的作用, 是输电线路中最重要的部件之一, 其状态是否正常关乎输电线路的安全运行. 根据国家电网公司统计, 在电力系统出现的故障中绝缘子故障可达 50% 以上, 是输电线路中最常见的故障^[1-2], 必须定期对其进行巡检和维

护. 目前国内外输变电工程中使用最广泛的绝缘子可分为玻璃、瓷质和复合绝缘子 3 类, 因为制造工艺和构成材料的不同, 出现的故障类型也有差异, 如复合绝缘子易出现伞裙破损故障, 玻璃绝缘子常出现自爆故障^[3]. 采用合适的图像处理算法实现绝缘子分类及故障检测, 对提高电网巡检效率, 保证

收稿日期 2022-07-06.

作者简介 王少飞(1996-), 男, 硕士研究生; 吴琼水(通信作者), 副教授, E-mail: qswu@whu.edu.cn.

基金项目 国家自然科学基金资助项目(52177109); 湖北省重点研发计划资助项目(2020BAB109).

输电线路的平稳运行具有重要意义。

近年来,无人机巡检凭借安全高效、操控灵活、受限条件少以及成本低等一系列优势,逐渐成为国内外输电线路巡检的重要模式^[4-5]。因此,许多学者针对基于无人机巡检产生的海量图像数据对绝缘子智能检测开展了大量研究。李发光等^[6]提出了一种改进的 CenterNet 模型,实现对航拍图像绝缘子缺陷的检测;何宁辉等^[7]利用 Faster-RCNN 实现航拍图像绝缘子缺失检测,但是识别速度较慢;汪权等^[8]提出了一种基于 Gaussian-YOLOv3 的绝缘子检测算法,快速精确识别航拍图像中的绝缘子;Liu C 等^[9]提出一种改进 YOLOv3 网络来对具有复杂背景的航拍图像中的绝缘子缺陷进行检测,增加了低分辨率特征层中的特征重用和传播;Deng F 等^[10]提出一种深度卷积自动编码的绝缘子自爆小样本检测方法,该方法结合了监督学习和无监督学习的优点,适合于绝缘子自爆故障样本较少的情况。

然而在实际巡检过程中,无人机巡检存在续航时间短等问题,电网公司往往会结合不同巡检方法的特点采取多种方法协同巡检^[11],如常见的机巡为主、人巡为辅方式,甚至在一些复杂环境下必须依靠人工巡检方式^[12-13]。由于人工巡检拍摄距离较远,绝缘子尺寸往往很小,多为小目标,且拍摄角度多为仰拍,会使绝缘子串形态发生明显改变,受阳光干扰更为严重,同时由于受地形、员工素质等因素

限制,无法进行全方位多角度巡检,绝缘子受遮挡情况更严重。人机协同巡检大大增加了绝缘子图像收集量、来源面以及复杂程度,在数据分析过程中既要考虑航拍图像中复杂背景等因素的影响,又要关注人工仰拍造成的绝缘子目标更小、形态改变、遮挡等问题,对模型的处理能力要求更高^[14],因此研究适合人机协同巡检方式下的绝缘子分类及故障检测算法对提高输电线路巡检效率具有重要意义。

为了解决以上问题,本研究构建了人工+无人机协同巡检数据集,对两种巡检方式所采集图像的特征及差异进行分析,并提出一种 YOLOv5-TBT 模型,通过增加 Transformer 编码器,使用 BiFPN,添加小目标预测分支,提高模型对绝缘子目标的特征提取和表征能力,增强对小目标的检测识别能力,实现人机协同巡检方式下绝缘子分类及故障检测。

1 协同巡检数据集

为了使模型能够学习到无人机巡检与人工巡检图像的差异,构建了人机协同巡检数据集,共 12 377 张绝缘子图像,拍摄后未经过任何裁剪、放大等预处理,采集设备多样,包括无人机摄像头,巡检人员手持照相机、手机等,拍摄角度、背景、清晰程度差异较大,均为实际巡检作业中产生的真实数据,有利于提高模型的鲁棒性和泛化能力。

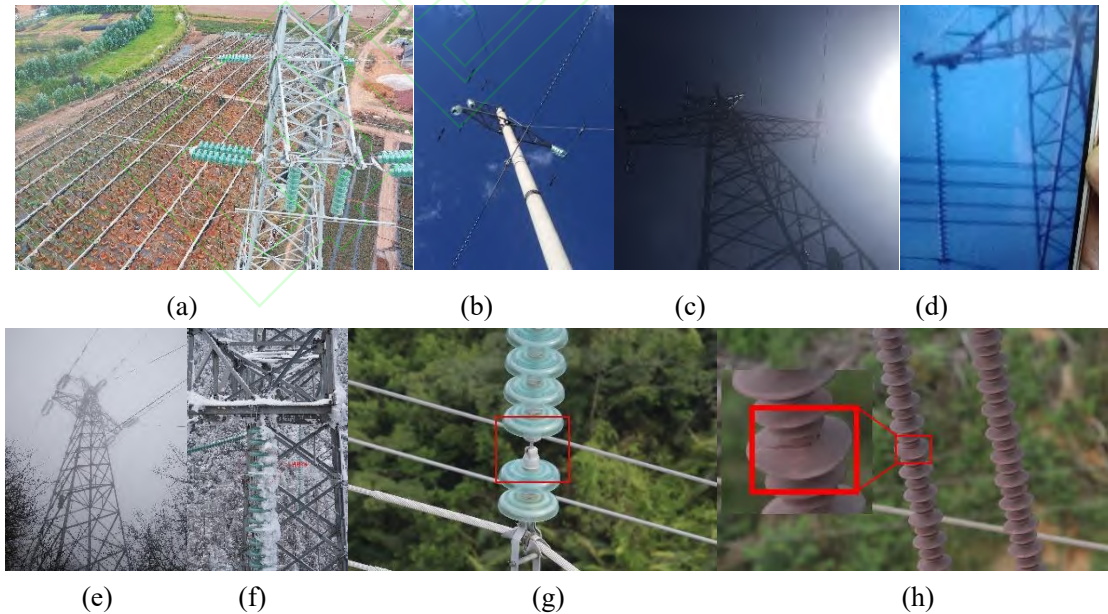


图1 部分绝缘子巡检图像

图1给出了数据集中部分绝缘子巡检图像。对数据集进行分析可以看出:无人机采集到的图像多为平拍或俯拍(图1(a)),能够很好地反映绝缘子串的整体特征,但是背景较为复杂,而人工巡检多为

仰拍(图1(b)),虽然背景相对简单,多为天空,但仰拍角度大,距离远,导致绝缘子目标更小,整体形态会发生较大变化;人工巡检更易受到光照(图1(c))、员工素质(图1(d))等因素影响,造成图像中

绝缘子难以识别;无论是无人机巡检还是人工巡检,都会因大雾(图 1(e))、冰雪(图 1(f))等恶劣天气导致图像质量下降;绝缘子常见的故障包括自爆(图 1(g))和伞裙破损(图 1(h)),由于故障目标比绝缘子目标小,特征不明显,检测难度明显高于绝缘子分类.这使得人机协同巡检数据更为复杂,给绝缘子准确分类与故障检测带来较大的困难.

2 改进 Yolov5-TBT 模型

2.1 网络结构

Yolov5(You only look once)是目前较为先进成熟的目标检测算法之一,在检测精度和速度上均表现优异,网络部署更为灵活.Yolov5 拥有 n, s, m,

l, x 五种版本,在精度、速度、网络规模等方面存在一定差异,如表 1 所示.由表 1 可以看出:在增加较少的参数量(Params)和计算量(FLOPs)的条件下,s 精度较 n 有大幅提高且速度不变,虽然 m, l, x 的精度相较于 s 有所提高,但是参数和计算量大增,因此,选取 Yolov5s 模型作为基础,代码版本为 v5.0.

表 1 不同版本的 Yolov5

模型	mAP0.5/%	速度/ms	参数量/ 10^6	计算量/ 10^9
Yolov5n	45.7	6.3	1.9	4.5
Yolov5s	56.8	6.4	7.5	16.5
Yolov5m	64.1	8.2	21.2	49.0
Yolov5l	67.3	10.1	46.5	109.1
Yolov5x	68.9	12.1	86.7	205.7

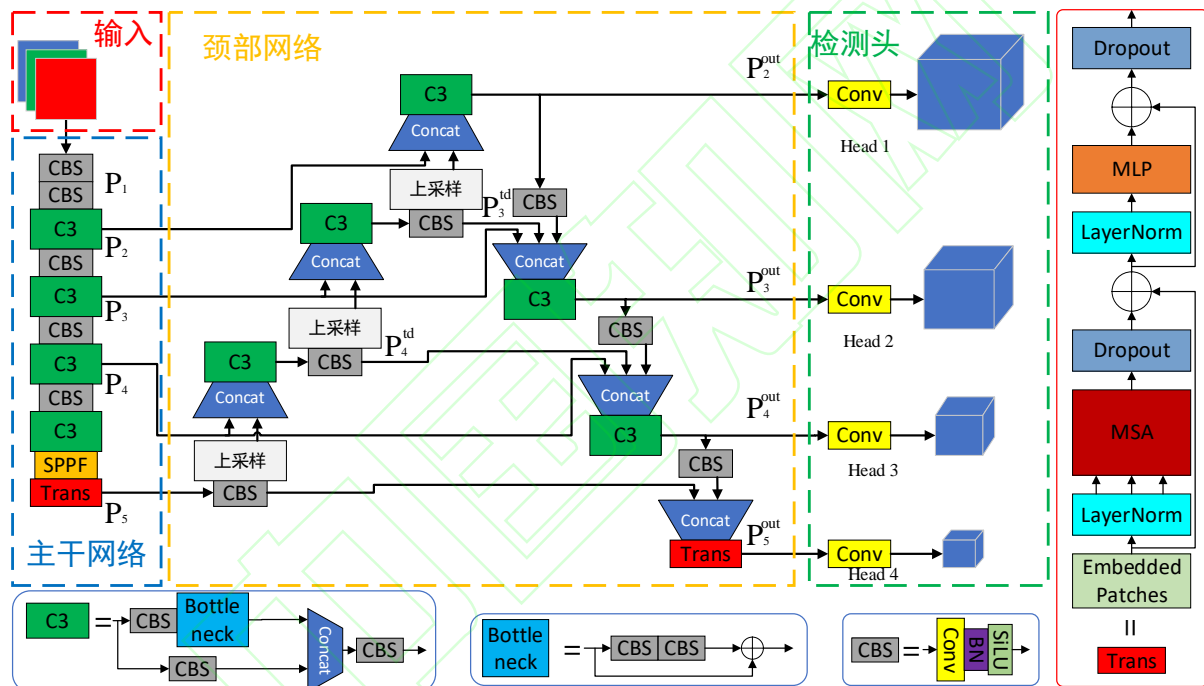


图 2 Yolov5-TBT 模型整体网络结构

针对人机协同巡检数据集中绝缘子目标尺寸小,形态差异大,遮挡严重,背景复杂,故障小目标难以检测等问题,提出一种改进的 Yolov5-TBT 目标检测模型,通过添加 Transformer 编码器、BiFPN 和小目标检测头,提高模型的特征提取、表征和融合能力以及对小目标的检测能力,实现绝缘子分类及故障诊断,Yolov5-TBT 模型整体网络结构如图 2 所示,图中 P_i^x 表示不同层级的特征图,Head i 表示检测头,CBS 模块包括卷积层(Conv)、归一化层(BN)和激活层(SiLU),Concat 负责将不同特征图在通道上进行拼接,□表示逐元素相加^[15],SPPF 为快速空间金字塔池化,MLP 为多层感知机,MSA 为多头自注意力.

Yolov5-TBT 主体结构包括输入(Input),主干网络(Backbone),颈部网络(Neck)和检测头(Detect)四部分,其中,Input 负责将不同尺寸的输入图像统一 Resize 成为 640×640 ,并通过 k-means 聚类算法获得最合适的先验框;Backbone(CSPDarknet53 + SPPF)负责特征提取,获得目标的各种语义信息和位置信息等特征,通过增加 Transformer 编码器,提高模型对绝缘子目标的特征提取能力,减少复杂背景的干扰;在 Neck 部分采用 BiFPN 替代 PANet^[16] (Path Aggregation Network),学习不同层级输入特征的重要性,实现更高效的多尺度特征融合,提高模型性能;最后在 Detect 添加一个高分辨率(160×160)的小目标预测分支(Head 1),提高模型对难识别小

目标的检测能力，联合原有的检测分支(20×20，40×40，80×80)预测目标的类别、置信度和预测框坐标，实现绝缘子目标的检测及故障诊断。

2.2 Transformer 编码器

由于巡检图像中绝缘子目标尺寸和形态差异较大，背景复杂，较小的绝缘子及故障目标往往会受到复杂背景的干扰，对模型的特征提取和表征能力提出更高的要求。受到 ViT^[17]启发，本文通过添加 Transformer 编码器，挖掘图像的关键信息和丰富的上下文信息，其核心思想是自注意力机制。人们在观察某一事物时，会重点关注感兴趣的部分，忽略不相关的部分，自注意力机制正是借鉴这一思路获取对当前任务起到关键作用的信息。

Transformer 编码器结构如图 2 中 Trans 部分所示，主要包括多头自注意力(MSA)和多层感知机(MLP)两大部分，其关键部件 MSA 可以使模型学习到前景和背景之间的联系，挖掘特征中的关键性信息，聚焦感兴趣的绝缘子目标，从而减轻复杂背景

带来的干扰，同时 Transformer 编码器的全局建模能力可以提高模型在目标重叠、遮挡等情况下的检测能力^[18]。如图 3 所示，将宽为 W ，高为 H ，通道数为 C 的输入图像划分为 N 个尺寸固定($P \times P$)的子图(Patches)后经线性映射及位置编码得到序列 X ，乘以不同的权重矩阵 W 后获得 MSA 的输入参数 Q ， K ， V ，分别表示由多个查询向量、键向量和值向量构成的矩阵，MSA 计算公式为

$$A(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k})V,$$

$$H_i = A(Q_i, K_i, V_i),$$

$$A_{Out} = \text{Concat}(H_1, \dots, H_h)W^O$$

式中： d_k 为 K 中某一行元素 k_i 的维度，即键向量的维度； A 为自注意力结果； h 为 MSA 的头数； H_i 为第 i 个头的自注意力结果； W^O 为可学习权重矩阵； A_{Out} 为输出结果，矩阵中某个位置的值越大，表示该子图区域越值得关注。

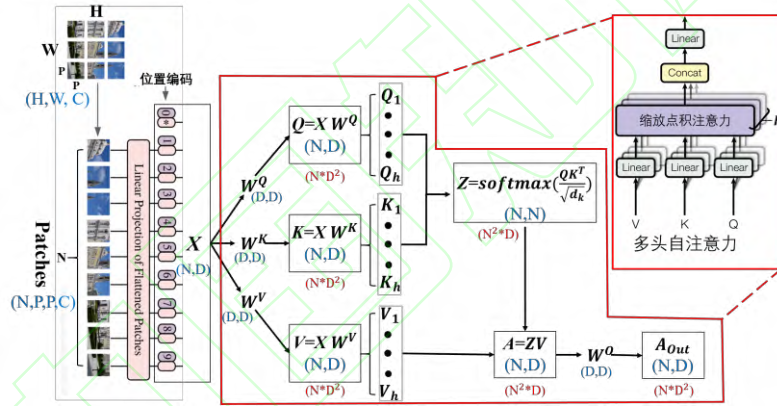


图 3 MSA 结构

图 3 中 $D=P^2C$ 为一个常数， $N=HW/P^2$ ，蓝色表示矩阵维度，红色表示计算复杂度，MSA 复杂度 $\Omega(\text{MSA})=4(HW/P^2)D^2+2(HW/P^2)^2D$ ，因此，为了平衡模型的精度与计算量，在 Backbone 末端和 Neck 中低分辨率特征图处应用 Transformer 编码器。

2.3 BiFPN

Yolov5 使用的 PANet 在进行特征融合时采用的是简单的线性相加，没有考虑到不同分辨率的输入特征图在进行特征融合时的贡献是不平等的，因此使用加权双向特征金字塔网络^[19](BiFPN)替代 PANet，通过引入可学习的权重参数学习不同输入特征图的重要性，实现更有效的多尺度特征融合。FPN，PANet 和 BiFPN 的结构如图 4 所示，图中最左侧数字表示不同层级特征图的尺寸。




图 4 Neck 改进

相较于 PANet，BiFPN 的特点在于：简化了网络结构，删除只有一条输入特征的节点，因为其没有进行特征融合，贡献较小；为处于同一层级的输入与输出特征图之间添加跳跃连接，在不增加计算成本的情况下增加特征交互；引入加权特征融合机制，为每个输入添加一个权重 ω_i ，用以判断各输入特征图的重要性，使用快速归一化特征融合方法，

$$O = \sum_i \frac{\omega_i I_i}{\varepsilon + \sum_j \omega_j},$$

式中： O 为融合后的输出特征； I 为进行特征融合的输入特征图； ω 为可学习权重，用于学习不同输入特征图的重要程度，利用常量 $\varepsilon=0.0001$ 保证数值稳定性。以第四层级特征融合为例，特征融合过程如下

$$P_4^{\text{td}} = \text{Conv}\left(\frac{\omega_1 P_4^{\text{in}} + \omega_2 \text{Resize}(P_5^{\text{in}})}{\omega_1 + \omega_2 + \varepsilon}\right);$$

$$P_4^{\text{out}} = \frac{\omega'_1 P_4^{\text{in}} + \omega'_2 P_4^{\text{td}} + \omega'_3 \text{Resize}(P_3^{\text{out}})}{\omega'_1 + \omega'_2 + \omega'_3 + \varepsilon},$$

式中： P_i^{in} 为第 i 层输入特征； P_4^{td} 为中间特征； P_i^{out} 为第 i 层输出特征，不同输入特征的重要性由对应的 ω 决定；Resize 为上采样或下采样操作。

2.4 小目标检测分支

对巡检数据集进行分析后，发现图像中绝缘子目标存在较大的尺度差异，且多数目标在图像中所占比例较小，如图 5 所示，图中 W_t , H_t , W_i , H_i 分别表示目标真实框和输入图片的宽高， $\text{weight}=W_t/W_i$, $\text{height}=H_t/H_i$ ，图 5 左侧中蓝色越深说明符合该比例的标签数量越多。




图 5 绝缘子标签尺寸分布

随着网络层级的加深，特征图分辨率不断变小，感受野变大，输入图像中小目标的特征会被淹没甚至丢失。为了缓解目标尺度剧烈变化带来的不利影响，提高模型对小目标的检测能力，增加一个低层级、高分辨率(160×160)、小感受野的检测头(Head 1)，如图 6 所示，中间特征图 P_3^{td} 经上采样后与高分辨率输入特征图 P_2 融合获得 Head 1 输入特征图 P_2^{out} ，同时在 P_3 与 P_3^{out} 之间添加跳跃连接。




图 6 小目标检测分支

3 实验结果及分析

3.1 实验配置

实验环境：操作系统为 Ubuntu18.04，显卡配置为 Quadro RTX6000，显存为 24 GiB；软件平台为 Python3.7，CUDA 10.2，Pytorch 1.10.2。

数据集来自某电网公司科技项目，包含实际巡检图像共 12 377 张，使用 labellmg 软件对图像中五类目标进行手工标注，分别是玻璃绝缘子、陶瓷绝缘子、复合绝缘子、绝缘子自爆和伞裙破损，实验中将数据集按 9:1 的比例划分为训练集和测试集，绝缘子图像及各类别标签数量分布如表 2 所示。

表 2 数据集图片及标签数量

目标	总数	训练集	测试集
巡检图片	12 377	11 139	1 238
玻璃绝缘子	31 943	28 612	3 338
陶瓷绝缘子	5 757	5 293	464
复合绝缘子	5 285	4 765	520
绝缘子自爆	2 485	2 243	242
伞裙破损	999	906	93

训练细节：在训练过程中，由于改变了模型的网络结构，因此未使用预训练权重进行训练，优化器采用 SGD 进行权值更新，权重衰减系数 (weight_decay) 设置为 0.000 5，设置学习率 $lr_0=0.01$ ， $lrf=0.01$ ，采用余弦退火策略自动更新学习率，学习率首先经过 3 个 epoch 从 $lr_0/3$ 线性上升至 lr_0 ，再呈余弦变化逐渐衰退到 $lr_0 \times lrf=1 \times 10^{-4}$ 。批量大小 (batch-size) 为 16，训练周期(epoch)为 150，输入图像尺寸为 640×640。

模型的损失函数包括边框损失、置信度损失和分类损失，训练过程中使用 CIoU loss 计算边框损失，使用 BCE loss 计算置信度和分类损失，训练 150 epoch 后损失函数逐渐收敛，如图 7 所示。




图 7 训练损失曲线

3.2 评价指标

为了对模型性能进行定量分析，使用平均精度均值(mAP)作为准确性评价指标，使用单张图片平均处理时间(Time)作为模型速度评价指标，其中 mAP 指标首先基于各类别准确率(P)和召回率(R)计

算各类别的平均精度(AP),接着对所有类别 AP 计算均值,对模型的综合性能进行评估,具体公式如下:

$$mAP = \frac{1}{C} \sum_{i=0}^C AP_i$$

式中: C 为类别数; AP 为各类别平均精度,通过对各类别 P-R 曲线积分计算得到,

$$AP = \int_0^1 p(r)dr$$

式中: $p(r)$ 表示召回率 $R=r$ 时准确率 $P=p$, 准确率

$P=TP/(TP+FP)$, 召回率 $R=TP/(TP+FN)$. TP , FP , FN 分别表示正确检测数量, 误检数和漏检数.

3.3 不同算法的对比实验

为验证本算法的优势,采用目前主流的深度学习目标检测模型,包括二阶段模型 Faster-RCNN^[20], 无锚框模型 FCOS^[21], YoloX-s^[22], YoloR-s^[23]和一阶段模型 SSD^[24], YOLOv5s, 在相同的训练条件和数据集下进行对比实验,输入图像尺寸除 SSD 模型为 512×512, 其余均为 640×640, 结果如表 3 所示.

表 3 不同算法对比实验结果

算法模型 评价指标	FCOS	SSD	Faster-RCNN	YoloX-s	YoloR-s	Yolov5s	Yolov5-TBT
玻璃绝缘子 AP/%	77.4	77.6	80.2	88.9	90.9	93.1	91.8
陶瓷绝缘子 AP/%	65.5	68.3	77.3	83.9	80.5	81.9	80.0
复合绝缘子 AP/%	57.9	65.2	68.3	77.3	77.7	76.6	78.3
绝缘子自爆 AP/%	57.2	63.5	71.3	75.3	71.4	76.7	76.8
伞裙破损 AP/%	54.9	44.9	62.0	52.8	51.9	47.2	66.6
mAP/%	62.6	63.9	71.8	75.6	74.5	75.1	78.7
时间/s	0.024	0.041	0.044	0.013	0.014	0.007	0.009

通过表 3 可以看出: Faster-RCNN 模型由于利用了区域建议网络(RPN)生成合适的目标推荐框,在小目标伞裙破损检测上取得了不错的性能,但是整体 mAP 和速度不如 YOLOv5s 模型. 而 YOLOv5s 模型整体检测性能优于前两种模型,但由于其将图像划分为 $S \times S$ 个网格,每个网格只负责使用预设的锚框预测中心点落于该网格处的目标,不利于小目标的检测检测,因此 YOLOv5s 模型对小目标伞裙破损的检测能力较差,只有 47.2%. YoloX 和 YoloR 模型作为 Yolo 系列的后起之秀,在检测精度上与 YOLOv5s 相差不多,但其检测速度有所下降且对故障小目标检测能力依然有待提高.

改进 YOLOv5-TBT 模型在整体性能上优于其它模型, mAP 达到 78.7%, 相较于 FCOS, SSD, Faster-RCNN, YoloX-s, YoloR-s 和 YOLOv5s 模型分别提高了 16.1%, 14.8%, 6.9%, 2.5%, 4.2%和 3.6%, 且对较难检测的伞裙破损故障识别精度达到 66.6%, 比 YOLOv5s 模型提高 19.4%, 对难识别小目标的检测能力有较大的提升,在检测速度方面稍逊色于 YOLOv5s 模型,但依然在毫秒级,且优于其他模型. 此外,发现在对玻璃绝缘子和陶瓷绝缘子的检测精度上,改进的 YOLOv5-TBT 模型并未取得最优效果,主要原因可能是由于这两类目标存在较大的尺度差异,大尺寸目标的数量相对较多,而改进方法使得模型更重视学习小目标的特征,从而影响到了这两

类目标的检测,但庆幸的是差距并不明显,仍在可接受的范围内,依然具有较高的预测精度.

总体而言,改进 YOLOv5-TBT 模型在整体检测精度上优于其它模型,且大幅提升了对难识别小目标伞裙破损的检测精度,在检测速度方面同样极具优势.

3.4 消融实验

为了验证各模块改进方法的合理性和有效性,设计了控制变量实验,依次增加 Transformer 编码器, BiFPN 及小目标检测分支,在相同实验条件下对模型检测精度进行测试,消融实验结果如表 4 所示.

由表 4 可见:在加入 Transformer 编码器后,模型整体性能有了较大提高, mAP 上升了 2.2%,说明 Transformer 编码器能够有效提高模型对绝缘子目标的特征提取能力,检测效果提升显著. 后续依次加入 BiFPN 和小目标检测分支,整体 mAP 检测精度得到持续提升,相较于 YOLOv5s 模型分别提升了 2.9%和 3.6%,验证了各模块的有效性.

表 4 消融实验结果

实验	Transformer 编码器	BiFPN	小目标检测 分支	mAP /%
1				75.1
2	✓			77.3
3	✓	✓		78.0
4	✓	✓	✓	78.7

注:“✓”表示该次实验中使用了该模块.

3.5 绝缘子分类及故障检测效果

为了更直观地展示 Yolov5s 模型与 Yolov5-TBT 模型的实际检测效果,对二者输出的预测结果进行可视化,红色、粉色、棕色、橙色和黄色实线框分别表示模型对玻璃绝缘子、陶瓷绝缘子、复合绝缘子、绝缘子自爆和伞裙破损的预测结果,如图 8 所示。考虑到大部分绝缘子目标在图像中仅占较小的区域,为了凸显 Yolov5-TBT 模型的优越性,在 Yolov5s 模型的输出图像中使用虚线框将漏检误检的目标区域进行放大,更清晰地展示二者检测效果的差异。

从图 8 的第一张图可以看出:绝缘子在远距离低角度拍摄时,由于绝缘子非常小以及形状变化,

Yolov5s 模型容易漏检,而改进的 Yolov5-TBT 模型可以很好地缓解这一问题。同时,在巡检图像中绝缘子有不同程度的遮挡,如图 8 中的第二和第三张图所示,得益于更强的特征提取和表示能力,Yolov5-TBT 模型可以更准确地检测出被遮挡绝缘子,同时预测包围框也更准确。此外,图 8 最后一张图表明,Yolov5-TBT 模型对特征不明显的故障小目标(如伞裙破损)的检测能力得到了明显提高。

同时,图 8 的前两幅图为人工巡检数据,后两幅图为无人机巡检数据,通过与 Yolov5s 预测结果进行对比,可以看出 Yolov5-TBT 模型在人工巡检和无人机巡检数据上的检测效果均优于 Yolov5s,能够更好地适应人机协同巡检数据集。

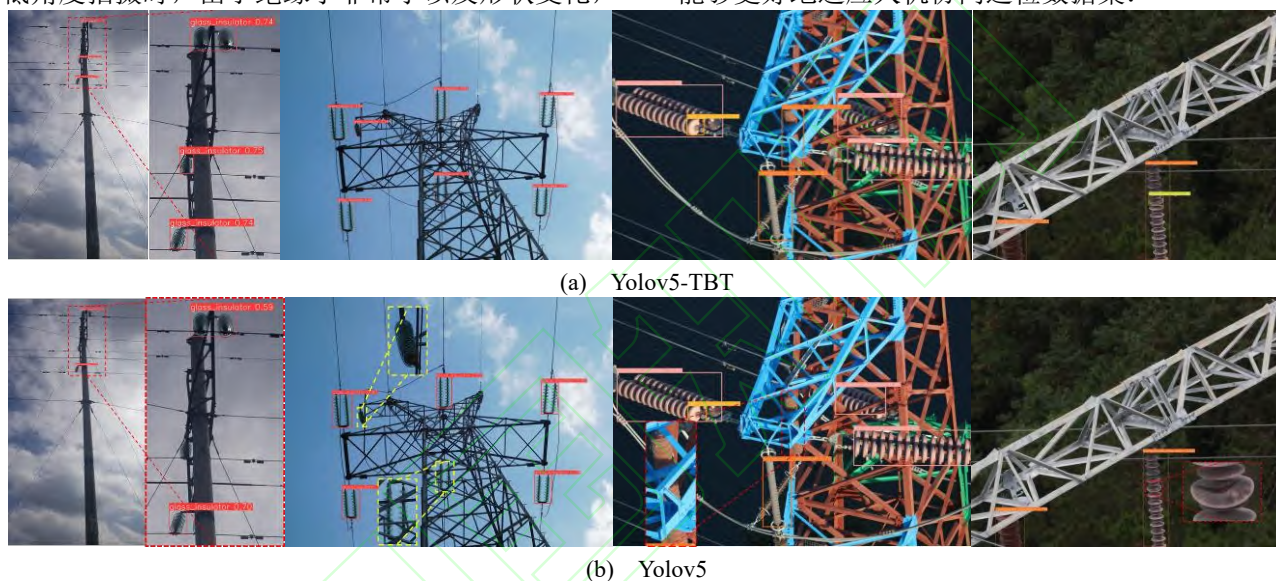


图 8 绝缘子分类及故障检测可视化结果

4 结语

改进后的 Yolov5-TBT 模型将 Yolov5s 与 Transformer 编码器相结合,缓解复杂背景的影响,优化特征提取网络;采用 BiFPN 学习不同层次特征图的重要性;增加小目标检测层提高对小目标的检测能力。

在构建的数据集上对不同模型分别进行训练和测试,验证了改进的 Yolov5-TBT 模型的有效性。相较于 FCOS, SSD, Faster-RCNN, YoloX-s, YoloR-s 模型,分别提高了 16.1%, 14.8%, 6.9%, 2.5%, 4.2%, 且检测速度优于上述模型。与 Yolov5s 模型相比,Yolov5-TBT 模型对伞裙破损的检测 AP 提高了 19.4%,整体 mAP 提高了 3.6%。

Yolov5-TBT 模型在人机协同巡检方式下拥有良好的绝缘子分类和故障检测性能,具备实际应用

于输电线路检测的潜力。

参考文献

- [1]秦钟,杨建国,王海默,等.基于 Retinex 理论的低照度下输电线路图像增强方法及应用[J].电力系统保护与控制,2021,49(3):150-157.
- [2]王建辉.基于航拍图像的绝缘子故障检测方法研究[D].太原:太原理工大学,2021.
- [3]HUANG X B, ZHANG H Y, ZHANG Y. Automatic identification and location technology of glass insulator self-shattering[J]. Journal of Electronic Imaging, 2017, 26(6): 063014.
- [4]隋宇,宁平凡,牛萍娟,等.面向架空输电线路的挂载无人机电力巡检技术研究综述[J].电网技术,2021,45(9):3636-3648.
- [5]顾晓东,唐丹宏,黄晓华.基于深度学习的电网巡检图像缺陷检测与识别[J].电力系统保护与控制,2021,49(5):

91-97.

[6]李发光, 伊力哈木·亚尔买买提. 基于改进 CenterNet 的航拍绝缘子缺陷实时检测模型[J]. 计算机科学, 49(5): 84-91.

[7]程海燕, 翟永杰, 陈瑞. 基于 Faster R-CNN 的航拍图像中绝缘子识别[J]. 现代电子技术, 2019, 42(2): 98-102.

[8]汪权, 易本顺. 基于 Gaussian YOLOv3 的航拍图像绝缘子缺陷识别[J]. 激光与光电子学进展, 2021, 58(12): 254-260.

[9]LIU C, WU Y, LIU J, et al. Improved YOLOv3 network for insulator detection in aerial images with diverse background interference[J]. Electronics, 2021, 10(7): 771.

[10]Deng, F. A novel insulator defect detection scheme based on Deep Convolutional Auto-Encoder for small negative samples[J]. High Volt, 2022, 7(5): 925-935.

[11]黄新波, 刘新慧, 张烨, 等. 基于红蓝色差和改进 K-means 算法的航拍绝缘子分类识别方法[J]. 高电压技术, 2018, 44(5): 1528-1534.

[12]ZHANG M J, LI H W, ZHAO W H, et al. Application of deep learning in unmanned aerial vehicle patrol inspection of military optical cable line[J]. Optical Communication Research, 2018, 6: 57-61.

[13]秦奋, 姚红芳, 马蔡国, 等. 基于 Dijkstra 算法的输电线路人工巡检优化方法[J]. 浙江电力, 2021, 40(6): 49-53.

[14]李轶. 基于多源数据融合的电网巡检安全评价方法研究[D]. 宜昌: 三峡大学, 2019.

[15]谢经明, 刘默耘, 何文卓等. 基于轻量化 YOLO 的 X 射线焊缝图像信息检测[J]. 华中科技大学学报(自然科学版), 2021, 49(1): 1-5.

[16]LIU S, QI L, QIN H, et al. Path aggregation network for instance segmentation[C]//Proceedings of the IEEE conference

on computer vision and pattern recognition. Utah: IEEE, 2018: 8759-8768.

[17]DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: transformers for image recognition at scale[J]. arXiv preprint arXiv:2010. 11929.

[18]ZHU X, LYU S, WANG X, et al. TPH-YOLOv5: improved YOLOv5 based on transformer prediction head for object detection on drone-captured scenarios[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. Montreal: IEEE, 2021: 2778-2788.

[19]TAN M, PANG R, LE Q V. Efficientdet: scalable and efficient object detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 10781-10790.

[20]REN S, HE K, GIRSHICK R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 39(6): 1137-1149.

[21]TIAN Z, SHEN C, CHEN H, et al. Fcos: fully convolutional one-stage object detection[C]//Proceedings of the IEEE/CVF international conference on computer vision. Seoul: IEEE, 2019: 9627-9636.

[22]GE Z, LIU S, WANG F, et al. YOLOX: exceeding YOLO series in 2021[J]. arXiv preprint arXiv:2107. 08430, 2021.

[23]WANG C, YEH I, LIAO H M. You only learn one representation: unified network for multiple tasks [J]. arXiv preprint arXiv:2105. 04206, 2021.

[24]LIU W, ANGUELOV D, ERHAN D, et al. Ssd: single shot multibox detector[C]//Proceedings of the European Conference on Computer Vision. Springer: Cham, 2016: 21-37.